Uniwersytet Jagielloński w Krakowie

Wydział Fizyki, Astronomii i Informatyki Stosowanej

Piotr Kucharski

Nr albumu: 1124564

Uczenie agentów sterowania pojazdami kosmicznymi

Praca licencjacka
na kierunku Informatyka Stosowana

Praca wykonana pod kierunkiem
prof. dr hab. Piotra Białasa
Zakład Technologii Gier

Kraków 2020

Oświadczenie autora pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

.....	.....
Kraków, dnia	Podpis autora pracy

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

.....	.....
Kraków, dnia	Podpis kierującego pracą

Spis treści

1 Abstrakt

Niniejsza praca prezentuje proces trenowania parametrów sztucznej sieci neuronowej za pomocą uczenia ze wzmocnieniem. Zadaniem sieci neuronowej jest optymalne sterowanie pojazdami w środowisku symulowanej przestrzeni kosmicznej.

2 Środowisko

Na potrzeby tej pracy zaimplementowałem w języku C++ ciągłą, dwuwymiarową przestrzeń po której poruszają się pojazdy, którymi steruje agent podlegający uczeniu. Pojazdy przemieszczają się zgodnie z zasadami dynamiki Newtona, bez oporów wpływających na ich aktualną prędkość. Środowisko jest obiektem tworzonym i kontrolowanym z poziomu skryptu w Pythonie. Środowisko korzysta z bibliotek SFML[4], wykorzystywanej do renderowania stanu środowiska za pomocą prymitywnych kształtów, oraz BOOST[1], która dostarcza możliwość wywoływania funkcji zaimplementowanych w C++ z poziomu Pythona. BOOST implementuje również możliwość przekazywania adresów pamięci wektorów Numpy pomiędzy symulacją a algorytmem uczenia maszynowego. Interfejs komunikacji ze środowiskiem złożony jest z pięciu funkcji: konstruktor zwracający inteligentny współdzielony wskaźnik, funkcja aktualizacji stanu środowiska, funkcja pozwalająca przywrócić środowisko do stanu początkowego, informacja o tym czy środowisko jest nadal aktywne oraz destruktor. Funkcja aktualizacji środowiska przyjmuje na wejściu akcje i zwraca następny stan, nagrodę oraz informacje o tym, czy pojazd został zresetowany. Funkcja przywracająca Środowisko do stanu początkowego zwraca tylko stan.

2.1 Akcje

Algorytm uczenia ze wzmocnieniem kontroluje ruch pojazdu przy każdej aktualizacji środowiska podejmując decyzję z jaką mocą mają działać dwa silniki. Pierwszy silnik nadaje przyspieszenie w kierunku przodu pojazdu, a drugi przyspieszenie obrotowe. Dla uproszczenia treningu przestrzeń możliwych akcji pierwszego silnika jest dwuelementowa: włączony i wyłączony $[1, 0]$. Drugi silnik posiada trzy możliwe akcje: lewo, wyłączony, prawo $[-1, 0, 1]$. Przestrzeni akcji powstaje z iloczynu kartezjańskiego wektorów możliwych akcji obu silników. Dodatkowo z przestrzeni akcji usuwana jest akcja neutralna, oba silniki są wyłączone, gdyż w początkowym etapie uczenia ta akcja była faworyzowana, co prowadziło do stagnacji procesu uczenia. Daje to pięcioelementową przestrzeń akcji.

2.2 Stan

Algorytm uczenia podejmuje decyzję którą akcję wykonać w danym kroku na podstawie obserwacji stanów otrzymywanych ze środowiska. Obserwacje składają się z trzech liczb rzeczywistych odpowiadających kolejno szybkości pojazdu, kątowi pomiędzy kierunkiem statku a wektorem prędkości oraz prędkości kątowej.

$$\begin{aligned} &1)\ |Velocity| \\ &2)\ \measuredangle ShipDirection - \measuredangle Velocity \\ &3)\ AngualrVelocity \end{aligned} \tag{1}$$

Dodatkowo w scenariuszach w których celem jest dotarcie pojazdem do wyznaczonego punktu kontrolnego stan rozszerzany jest o dwie następne liczby rzeczywiste odpowiadające odległości pojazdu od wyznaczonego punktu oraz kątowi pomiędzy kierunkiem statku a wektorem odległości do tego punktu.

$$\begin{aligned} &4)\ |CheckpointPosition - ShipPosition| \\ &5)\ \measuredangle ShipDirection - \measuredangle(CheckpointPosition - ShipPosition) \end{aligned} \tag{2}$$

2.3 Graficzna reprezentacja środowiska

Rysunek 1: Pojazd.

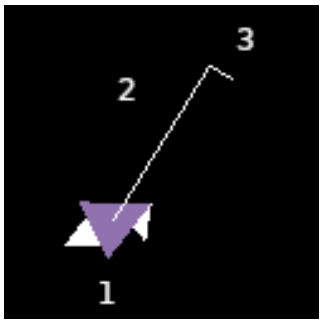

Pojazd (1) jest reprezentowany przez trzy trójkąty. Pierwszy największy kolorowy trójkąt reprezentuje pojazd. Najostrzejszy wierzchołek wskazuje przód pojazdu. Wielkość pozostałych dwóch trójkątów odpowiada mocy silników. Trójkąt połączony z krótszą krawędzią pojazdu reprezentuje główny silnik, a trójkąt połączony z najostrzejszym wierzchołkiem pojazdu reprezentuje silnik rotujący. Odcinki (2) oraz (3) są graficzną reprezentacją stanu pojazdu i odpowiadają prędkości oraz prędkości obrotowej.

2.4 Funkcja aktualizacji środowiska

Algorytm uczenia ze wzmocnieniem aktualizuje stan środowiska podając indeks wybranej akcji. W pierwszej kolejności obliczane jest przyspieszenie działające na pojazd, które zależy od wybranej przez algorytm mocy głównego silnika.

$$\begin{cases} Acceleration_x = firstAction * cos(ShipDirection) * mainEnginePower/mass \\ Acceleration_y = firstAction * sin(ShipDirection) * mainEnginePower/mass \end{cases} \tag{3}$$

Następnie obliczana jest prędkość pojazdu $Velocity = Velocity + Acceleration * timeStep$ oraz nowa pozycja pojazdu $ShipPosition = ShipPosition + Velocity * timeStep$. Środowisko aktualizowane jest ze stałym krokiem czasowym wynoszącym dziesiątą część sekundy.

$$
\begin{aligned}
AngularAcceleration &= secondAction * rotationEnginePower/(0.5 * mass * size) \\
AngualarVelocity &= AngualarVelocity + AngularAcceleration * timeStep \\
ShipDirection &= ShipDirection + AngularVelocity * timeStep
\end{aligned} \tag{4}
$$

Po zaktualizowaniu położenia pojazdu obliczana jest nagroda oraz sprawdzane są warunki kończące symulację pojazdu. Po aktualizacji funkcja zwraca krotkę z adresami pamięci, pod którymi znajdują się wektory zawierające następny stan, nagrodę oraz informację mówiącą o tym, czy pojazd zakończył symulację.

2.5 Scenariusze i modelowanie funkcji nagrody

Zaimplementowałem trzy scenariusze różniące się pomiędzy sobą sposobem obliczania nagrody oraz początkowym stanem pojazdu. We wszystkich scenariuszach pojazd posiada te same akcje, parametry oraz sposób aktualizacji. Interfejs komunikacji jest niezmienny.

Celem pierwszego scenariusza jest nauczenie agenta zmniejszania szybkości rozpędzonego pojazdu. Pojazd rozpoczyna symulację posiadając losową rotację, losową prędkość obrotową z zakresu $[-2, 2]$ rad/s oraz wektor prędkości którego elementy losowane są z zakresu $[5, 10]$ m/s. Po każdej aktualizacji środowiska agent otrzymuje nagrodę odpowiadającą odwrotnej zmianie szybkości w danym kroku $r_t = |Velocity_{t-1}| - |Velocity_t|$. Gdy szybkość pojazdu przekroczy 20 m/s lub gry szybkość obrotowa przekroczy 2 rad/s stan pojazdu jest ponownie losowany tak samo jak na początku symulacji, a agent otrzymuje ujemną nagrodę za wybranie akcji prowadzącej do spełnienia jednego z powyższych warunków. Agent otrzymuje dodatnią nagrodę po wykonaniu akcji prowadzącej do zmniejszenia szybkość pojazdu poniżej 2 m/s, po której stan pojazdu również jest losowany na nowo.

Celem drugiego i trzeciego scenariusza jest nauczenie agenta dolatywania pojazdem do wyznaczonego losowo punktu kontrolnego. Podobnie jak w pierwszym scenariuszu pojazd na początku posiada losową rotację, prędkość obrotową $[-1, 1]$ rad/s, oraz elementy wektora prędkość z zakresu $[0, 10]$ m/s. Pozycja pojazdu ustawiana jest na środek układu współrzędnych. Współrzędne punktu kontrolnego losowane są z zakresu $[-700, 700]$ m. Gdy pojazd zbliży się do punktu kontrolnego na mniej niż 25 metrów pojazd oraz punkt kontrolny są losowane na nowo, a agent otrzymuje dodatnią nagrodę. Gdy pojazd oddali się od punktu kontrolnego na więcej niż 1400 m lub jego szybkość obrotowa przekroczy 2 rad/s agent otrzymuje ujemną nagrodę, a stan pojazdu jest na nowo losowany. Punkt kontrolny pozostaje w tym samym położeniu. W drugim scenariuszu nagroda otrzymywana przez agenta po każdej aktualizacji odpowiada odwrotnej zmianie odległości pojazdu od punktu kontrolnego.

W trzecim scenariuszu nagroda odpowiada zmianie szybkości w kierunku punktu kontrolnego. - doprecyzuję

3 Definicja uczenia ze wzmocnieniem

Uczenie ze wzmocnieniem polega na optymalizacji strategii wybierania akcji na podstawie doświadczeń generowanych podczas interakcji ze środowiskiem. Proces decyzyjny Markowa jest matematycznym sformułowaniem procesu interakcji agenta ze środowiskiem, którego celem jest osiągnięcie najwyższej możliwej nagrody. Składa się z krotki (S, A, P, R), gdzie S to zbiór stanów środowiska w jakich może się znaleźć symulowany pojazd, A to zbiór akcji, $P(s'|s, a)$ to rozkład prawdopodobieństwa przejścia pomiędzy stanami w zależności od wybranej akcji, $R(s, a)$ to funkcja nagrody otrzymywanej przez agenta natychmiast po wykonaniu akcji w zadanym stanie. Proces interakcji ze środowiskiem tworzy sekwencję doświadczeń $S_1, A_1, R_1, S_2, A_2, R_2...S_T, A_T, R_T$, gdzie T oznacza numer kroku, w którym symulacja pojazdu jest resetowana. Strategię π definiuje się jako funkcję rozkładu prawdopodobieństwa akcji na zadanym stanie.

$$\pi(a|s) = \mathbb{P}[A_t = a|S_t = s] \tag{5}$$

Optymalna strategia π^* w każdym stanie ze zbioru S wybierze taką akcję, która da maksymalną obniżoną nagrodę którą agent jest w stanie uzyskać z danego stanu. Parametr zniżki $0 < \gamma < 1$ zmniejszający nagrody z przyszłych kroków zmusza agenta do podejmowania dobrych decyzji wcześniej. Gdyby zniżki przyszłych nagród nie było agent mógłby odwlekać wybranie dobrej akcji w nieskończoność. Maksymalna obniżona nagroda możliwa do uzyskania z danego stanu zdefiniowana jest jako optymalna funkcja wartości.

$$V^*(s) = \max_a [R(s, a) + \gamma \sum_{s'} P(s'|s, a)V^*(s')] \tag{6}$$

Maksymalna oczekiwana nagroda do uzyskania z danego stanu po podjęciu określonej akcji to optymalna funkcja wartości akcji Q^*.

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q^*(s', a') \tag{7}$$

$$V^*(s) = \max_a Q^*(s, a)$$

Jeśli optymalna wartość $Q^*(s', a')$ w następnym kroku jest znana dla wszystkich możliwych akcji a' to optymalną strategią podejmowania akcji jest wybieranie a' maksymalizując oczekiwaną obniżoną nagrodę.

$$\pi^*(s) = arg \max_a Q^*(s, a) \tag{8}$$

$$V_\pi(s) = \sum_a \pi(a|s)[R(s, a) + \gamma \sum_{s'} P(s'|s, a)V_\pi(s')] \tag{9}$$

$$Q_\pi(s,a) = R(s,a) + \gamma \sum_{s'} P(s'|s,a) \sum_{a'} \pi(a'|s') Q_\pi(s',a') \tag{10}$$

$$V_\pi(s) = \sum_a \pi(a|s) Q_\pi(s,a)$$

Funkcję (10) można rozwiązać iterując równanie Temporal Difference[8], gdzie α to wielkość kroku optymalizacyjnego. Taka iteracja funkcji wartości akcji zbiega do optymalnej funkcji $Q_i \to Q^*$ dla $i \ \to \infty$[8].

$$Q_{i+1}(s,a) = Q_t(s,a) + \alpha[R(s,a) + \gamma \sum_{s'} P(s'|s,a) \max_{a'} Q_t(s',a') - Q_t(s,a)] \tag{11}$$

Takie podejście jest niepraktyczne w przypadku tej pracy, gdyż przestrzeń stanów jest za duża oraz algorytm uczący nie ma dostępu do funkcji $P(s'|s,a)$.

4 Głębokie uczenie funkcji wartości akcji Q

Bez dostępu do funkcji przejścia $P(s'|s,a)$ proces optymalizacji musi bazować na seriach doświadczeń, które są generowane podczas interakcji ze środowiskiem. Serie składają się z krotek zawierających stan S_t, akcję A_t oraz otrzymaną nagrodę R_t. Elementy wszystkich serii są na zapisywane w pamięci M. Podczas analizy serii, bez podanej funkcji $P(s'|s,a)$, funkcja wartości jak i wartości akcji opiera się na założeniu, że kolejne akcje w serii były wybierane zgodnie ze strategią π.

$$V_\pi(s) = \mathbb{E}[R_t + \gamma V_\pi(S_{t+1}) | S_t = s, A_t \sim \pi(S_t)] \tag{12}$$

$$Q_\pi(s,a) = \mathbb{E}[R_t + \gamma Q_\pi(S_{t+1}, A_{t+1}) | S_t = s, A_t = a, \pi] \tag{13}$$

Celem znalezienia optymalnej strategii korzystam z funkcji z parametrami θ która aproksymuje optymalną funkcję wartości akcji $Q(s,a:\theta) \approx Q^*(s,a)$. W tej pracy funkcją jest głęboka sieć neuronowa z nieliniowymi aktywacjami. Sieć neuronową można uczyć minimalizując sekwencje funkcji kosztu $L_i(\theta_i)$. Funkcja kosztu odpowiada kwadratowi funkcji Temporal Difference z tą różnicą, że stan s, akcja a, nagroda r oraz stan po aktualizacji środowiska s' są losowane z pamięci wcześniejszych doświadczeń M.

$$L_i(\theta_i) = \mathbb{E}_{s,a,r,s' \sim M}[(r + \gamma \max_{a'} Q(s',a':\theta_{i-1}) - Q(s,a:\theta_i))^2] \tag{14}$$

Wagi sieci neuronowej optymalizuje się za pomocą stochastycznego spadku wzdłuż gradientu.

$$\nabla_{\theta_i} L_i(\theta_i) = \mathbb{E}_{s,a,r,s' \sim M}[(r + \gamma \max_{a'} Q(s',a':\theta_{i-1}) - Q(s,a:\theta_i)) \nabla_{\theta_i} Q(s,a:\theta_i)] \tag{15}$$

Krok optymalizacyjny następuje po każdej aktualizacji stanu środowiska. Wagi θ_{t-1} są podczas treningu zamrożone. Korzystanie z wag z poprzedniej aktualizacji mogłoby prowadzić do katastroficznego zapominania, dlatego wagi θ_{t-1} zastępowane są wagami θ_f które co stałą ilość kroków przyjmują aktualną wartość θ_t .

4.1 Problemy głębokiego uczenia ze wzmocnieniem

Kolejne stany środowiska są bardzo do siebie podobne, co w procesie uczenia prowadziłoby do nadmiernego dopasowania funkcji Q bądź zbiegania do lokalnego minimum. Celem uniknięcia tej sytuacji pamięć M ma dużą pojemność n, a partie do uczenia o wielkości $b < n$ są wybierane z pamięci z jednakowym prawdopodobieństwem $(S_b, A_b, R_b, S'_b) \sim M$. Prowadzi to do zwiększenia niezależności stanów, na podstawie których obliczany jest krok uczący. Drugim sposobem na przeciwdziałanie podobieństwa stanów jest jednoczesne symulowanie wielu niezależnych pojazdów, które są inicjalizowane w sposób losowy. Prowadzi to do lepszej eksploracji przestrzeni stanów oraz pozwala na lepszą ewaluację aktualnej strategii podczas treningu. Wyniki przeprowadzonych eksperymentów wskazują na znaczącą poprawę wyników już przy pięciu symulowanych jednocześnie pojazdach.

Gdyby agent od początku chciwie podejmował akcje na podstawie losowo zainicjalizowanej funkcji wartości akcji $a_t = \max_a Q(s_t, a : \theta)$ mógłby, przez niedostateczną eksplorację, pozostać w lokalnym minimum. Eksplorację wymusza się na agencie poprzez wybieranie z prawdopodobieństwem ϵ losowej akcji $a_t \sim A$, a z prawdopodobieństwem $1-\epsilon$ akcji chciwej $a_t = \max_a Q(s_t, a : \theta)$. Ten sposób podejmowania akcji nazywa się ϵ-greedy[8]. Wartość ϵ jest warunkowana początkową wartością ϵ_{start}, końcową wartością ϵ_{end} oraz liczbą kroków ϵ_{decay} po których ϵ ma osiągnąć wartość końcową. W trakcie treningu ϵ zmniejsza się z każdym krokiem zgodnie z równaniem $\epsilon_t = \epsilon_{end} + (\epsilon_{start} - \epsilon_{end})e^{(-t/\epsilon_{decay})}$.

Następnym problemem w głębokim uczeniu ze wzmocnieniem są eksplodujące gradienty. Główną przyczyną eksplozji jest duże odchylenie standardowe obserwowanych nagród oraz stany zawierające zmienne o różnych rzędach wielkości. Wagi sieci θ_{t-1} służą do obliczania funkcji kosztu jak generowane stany podczas interakcji ze środowiskiem zależne są od wag θ. Z tych powodów problem eksplodujących gradientów występuje w uczeniu ze wzmocnieniem częściej niż w przypadku innych dziedzin uczenia maszynowego. Żeby przeciwdziałać eksplodującym gradientom korzystam z funkcji kosztu $smooth\_L1\_loss$[3] celem zmniejszenia wpływu skrajnych pomiarów na całkowity gradient danego kroku uczącego.

$$smooth_{L_1}(x) = \begin{cases} 0.5x^2 & dla |x| < 1 \\ |x| - 0.5 & dla |x| \geq 1 \end{cases} \tag{16}$$

Podobnie jak w Atari DQN[6] korzystam z optymalizatora $RMSprop$ zaproponowanego przez G. Hintona[9] i po raz pierwszy opublikowanego w pracy na temat optymalizacji rekurencyjnych sieci neuronowych służących do generowania tekstu[5]. Optymizator przechowuje średnią kroczącą kwadratów gradientów dla każdej wagi $w \in \theta$, a podczas aktualizacji wagi dzieli

gradient przez pierwiastek kwadratowy tej średniej.

$$\mathbb{E}[g^2]_t = \beta\mathbb{E}[g^2]_{t-1} + (1-\beta)(\frac{\delta L(x)}{\delta w})^2 \tag{17}$$

$$w_t = w_{t-1} - \frac{\alpha}{\sqrt{\mathbb{E}[g^2]_t}}\frac{\delta L(x)}{\delta w} \tag{18}$$

4.2 Algorytm

Algorithm 1: Głębokie uczenie Q-network z wykorzystaniem pamięci

Inicjalizacja parametrów θ funkcji wartości akcji Q, $\theta_f = \theta$
Inizjalizacja środowiska oraz otrzymanie pierwszego stanus_1
for *t=0; t<T; t++* **do**
  Z prawdopodobieństwem ϵ wybierz losową akcję $a_t \sim A$,
  w innym przypadku wybierz $a_t = \max_a Q(s_t, a : \theta)$
  Zaktualizuj stan środowiska wykonując akcję a_t otrzymując (r_t, s_{t+1})
  Zapisz w pamięci element (s_t, a_t, r_t, s_{t+1})
  if *t>b* **then**
    $(S_b, A_b, R_b, S'_b) \sim M$
    Zaktualizuj wagi θ zgodnie z $(R_b + \gamma \max_{a'} Q(S'_b, a' : \theta_f) - Q(S_b, A_b : \theta))^2$
  end
  if *(t % częstotliwość aktualizacji θ_f) == 0* **then**
    $\theta_f = \theta$
  end
end

4.3 Sztuczna sieć neuronowa

Funkcja aproksymująca Q^* jest złożona z wielu warstw funkjci liniowych zawierających nieliniowe aktywacje pomiędzy kolejnymi warstwami. Pierwsza funkcja liniowa przyjmuje na wejściu stan otrzymany ze środowiska, przekształca na wektor o wymiarze w a następnie oblicza nieliniową funkcję aktywacji $ReLu$[2] na wektorze wyjściowym. Kolejne d funkcji liniowych o tej samej szerokości w przekształca wektor w ten sam sposób co pierwsza funkcja. Ostatnia funkcja liniowa przekształca wektor o wymiarze w na wektor o wymiarze odpowiadającym rozmiarowi przestrzeni akcji A. Wektor wyjściowy odpowiada wartości wszystkich akcji. W tej pracy korzystam z algorytmów uczenia maszynowego zaimplementowanych w bibiliotece PyTorch[7].

5 System do przeprowadzania eksperymentów

Chcąc przetestować w jaki sposób algorytm uczenia DQN reaguje na różne parametry potrzebowałem systemu przechowującego wyniki przeprowadzonych eksperymentów, kolejkę eksperymentów do wykonania oraz proces, który wykonuje kolejne eksperymenty. Dzięki uprzejmości Naukowego Koła Robotyki i Sztucznej Inteligencji na Uniwersytecie Jagiellońskim miałem dostęp do dwóch maszyn obliczeniowych, co wymagało napisania dodatkowych narzędzi odpowiedzialnych za synchronizację kolejki eksperymentów i wyników.

5.1 Tworzenie eksperymentów

Szablon eksperymentów tworzony jest po wskazaniu plików tekstowych w formacie JSON, które zawierają domyślne parametry potrzebne do uruchomienia danego eksperymentu. Szablon można uruchomić jako eksperyment lub można go wykorzystać jako bazę do stworzenia wielu eksperymentów, nazywanych serią, różniących się pomiędzy sobą parametrami. Serię eksperymentów tworzy się podając folder, w którym znajduje się szablon, oraz listy wartości parametrów. Eksperymenty tworzone są z elementów iloczynu wszystkich list wartości parametrów, a następnie zapisywane są w folderze kolejki.

5.2 Uruchamianie obliczeń

Po stworzeniu serii można lokalnie uruchomić skrypt *runq.sh* wykonujący lokalnie eksperymenty z kolejki. W celu wysłania części eksperymentów na zdalne maszyny trzeba uruchomić skrypt *split_training.sh* który dzieli eksperymenty z kolejki i wysyła je przez ssh do maszyn obliczeniowych. Po uruchomieniu skryptu eksperymenty są losowo dzielone na równe części dla każdej z maszyn zapisanych w pliku $remote\_config.py$. Po podzieleniu eksperymenty są kompresowane a następnie przesyłane na maszynę. Po przesłaniu pliku eksperymenty są rozpakowywane i umieszczane w folderze kolejki. Za pomocą skryptu *work.py* można uruchomić skrypt *runq.sh* na wszystkich zdalnych maszynach. Podczas obliczeń można uruchomić skrypt *status.py* celem sprawdzenia ilości pozostałych eksperymentów na maszynach oraz utylizacji procesora kart graficznych.

5.3 Synchronizacja wyników

Żeby pobrać z maszyn wyniki eksperymentów które zostały zakończone trzeba uruchomić skrypt *pull.py*. Skrypt ten wysyła na maszynę listę plików które znajdują się lokalnie. Maszyna po porównaniu lokalnych plików z otrzymaną listą kompresuje te pliki, które nie znajdowały się na liście. Skrypt następnie pobiera skompresowane wyniki i rozpakowuje je lokalnie.

6 Przeprowadzone eksperymenty

Chcąc dokładnie poznać możliwości jednego z algorytmów uczenia ze wzmocnieniem zdecydowałem się na zastosowanie metodologii przeszukiwania siatki, co pozwoliło mi sprawdzić wpływ różnych kombinacji hiper parametrów na wyniki uczenia. Główną wadą tego podejścia okazał się być długi czas obliczeń niezbędny do wykonania wszystkich eksperymentów.

7 Wyniki treningu

Liczba aktualizacji wszystkich eksperymentów wynosiła milion kroków uczących. Na wykresach w tym rozdziale pozioma oś odpowiada numerze kroku uczącego podzielonego przez częstotliwość zapisywania nagrody podczas treningu, a pionowa oś odpowiada uzyskanej przez algorytm nagrodzie. Na wykresach znajdują się średnie kroczące średniej wszystkich eksperymentów z danym parametrem. W poniższych rozdziałach omawiam różnicę w parametrach które mają wpływ na wyniki treningu.

7.1 Pierwszy scenariusz

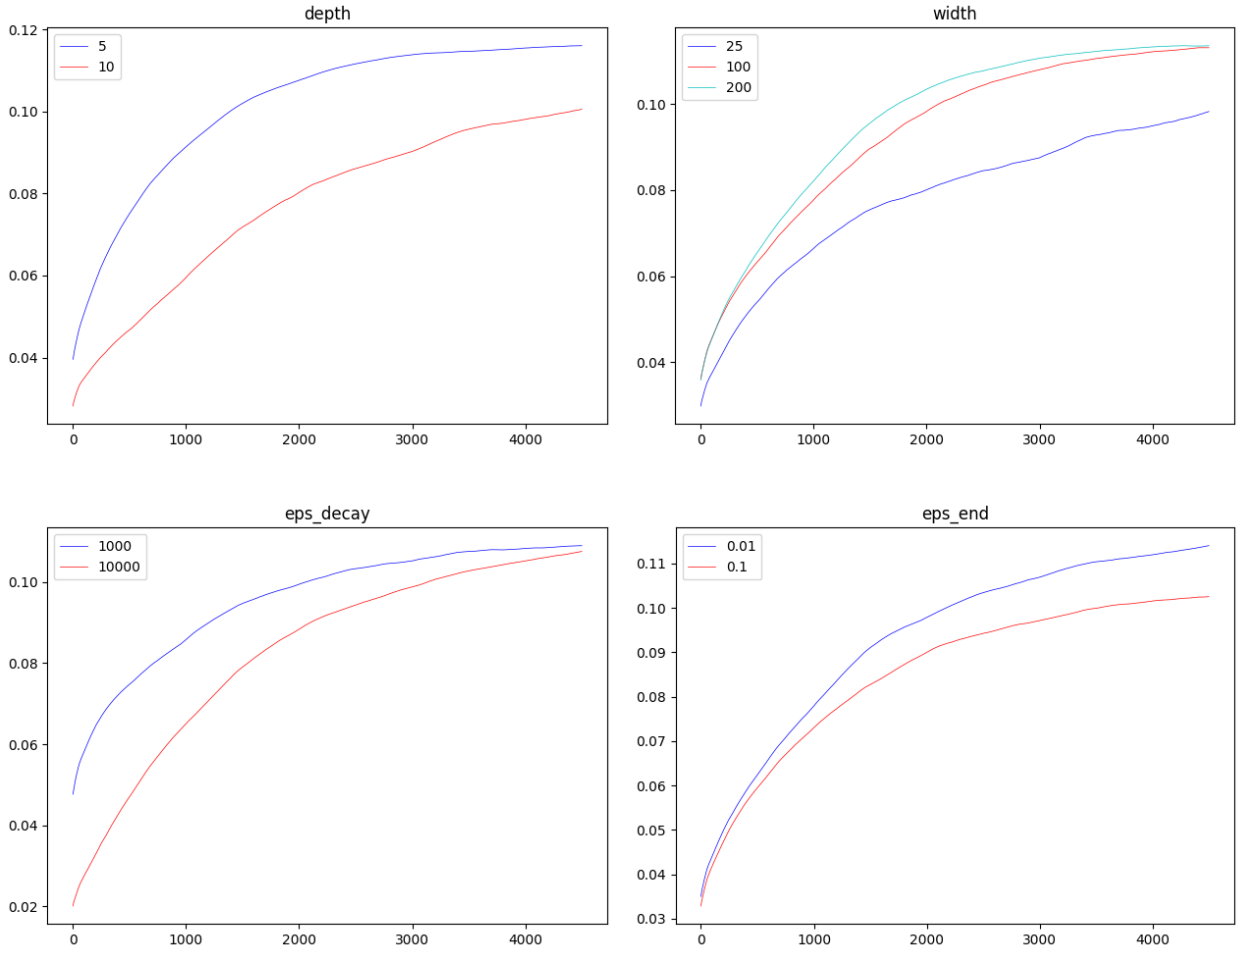

Rysunek 2: Wyniki treningu w pierwszym środowisku.

Pierwszy scenariusz polegający na zatrzymywaniu pojazdu okazał jest najłatwiejszym środowiskiem do rozwiązania, co można wnioskować obserwując niewielkie postępy w końcowym etapie uczenia po początkowym okresie dynamicznego wzrostu. Sieć o mniejszej ilości szerszych warstw spisywała się lepiej od bardziej rozbudowanych sieci neuronowych. Parametry kontrolujące sposób eksploracji wpływają na wynik treningu zgodnie z oczekiwaniami. Większy (*eps_end*) powoduje częstsze wybieranie losowej akcji i co za tym idzie zaniża nagrodę funkcji dobrze dopasowanej. Mniejszy (*eps_decay*) skraca okres eksploracji pozwalając na lepsze dopasowanie funkcji w przypadku prostych środowisk. W trudniejszych środowiskach zwiększona stabilność i dłuższa eksploracja zwiększonym (*eps_decay*) może być pożądana.

7.2 Drugi scenariusz

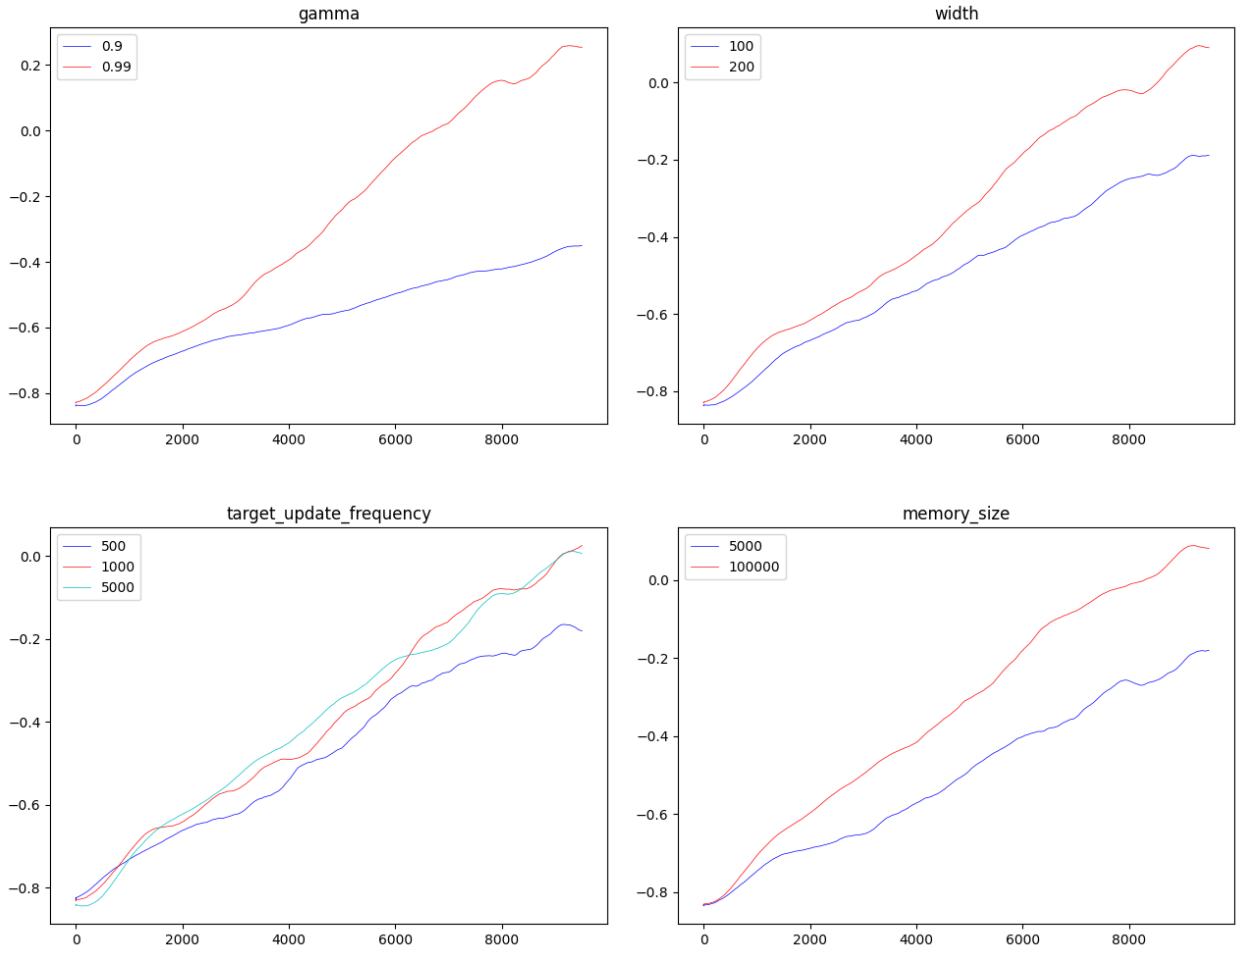

Rysunek 3: Wyniki treningu w drugim środowisku.

W drugim scenariuszu widać nietypowy, liniowy przyrost zdobywanej przez agenta nagrody. Wynika to ze sposobu obliczania nagrody który odpowiada zmianie odległości. Zwiększenie pamięci poprawiło osiągane wyniki oraz stabilność treningu. Zwiększenie parametru (*gamma*) kontrolującego planowanie również poprawiło wyniki. Pojawia się też zauważalny wpływ częstotliwości aktualizacji wag sieci na podstawie której obliczana jest maksymalna wartość akcji z następnego kroku.

7.3 Trzeci scenariusz

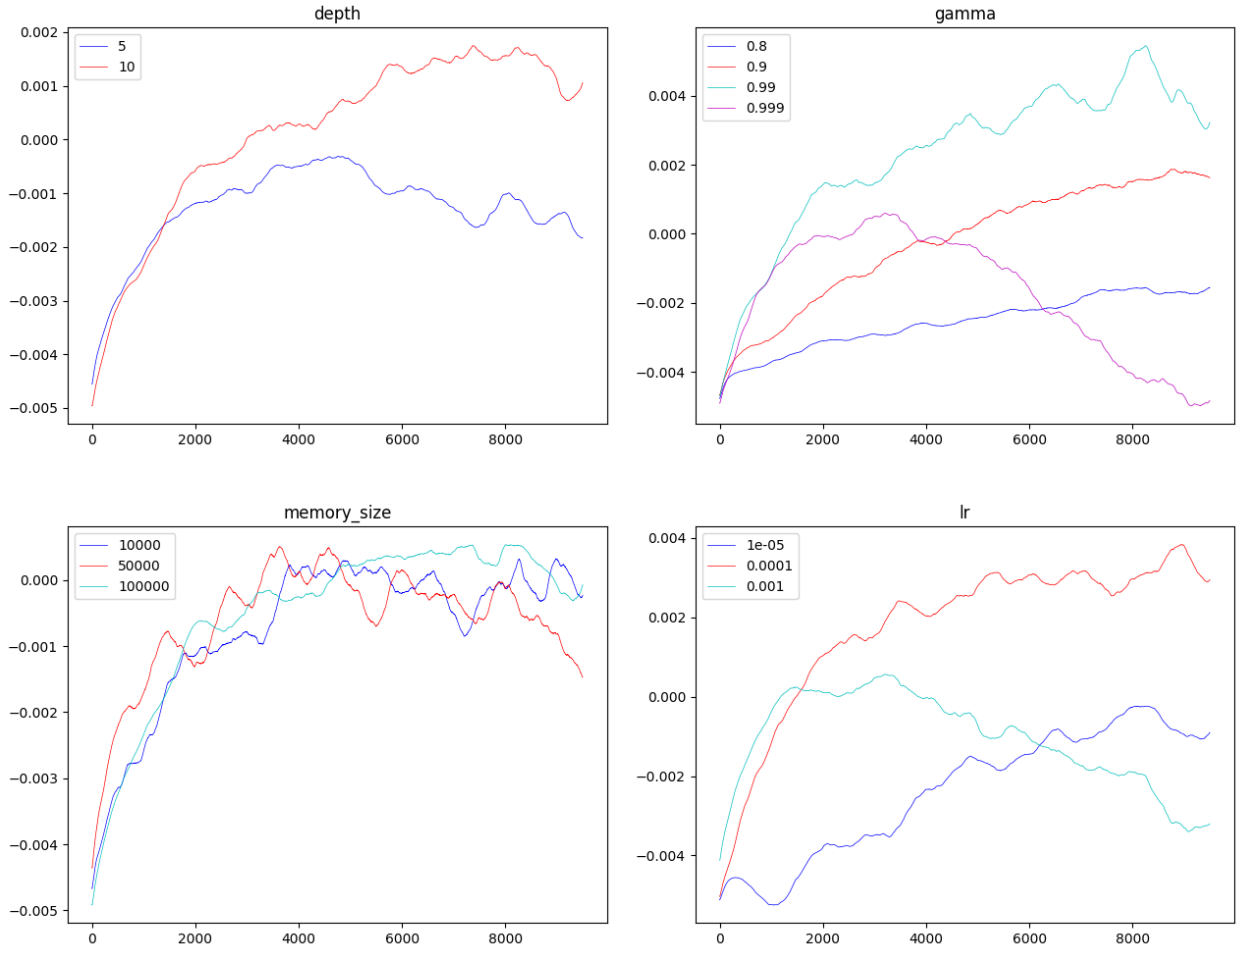

Rysunek 4: Wyniki treningu w trzecim środowisku.

W przeciwieństwie do pierwszego scenariusza trzeci scenariusz jest bardziej skomplikowany. Pogłębienie sieci neuronowej przyniosło lepsze rezultaty. Parametr *gamma* nie powinien przyjmować wartości bliskich jeden, gdyż dochodzi do tragicznego zapominania. Mniejsza wartość tego parametru nie wpływa tak negatywnie na wydajność nauki jak za duża wartość. Krok uczący o wielkości 0.0001 (lr) okazał się być najlepszy i został zastosowany również w pozostałych środowiskach.

8 Wyniki testów

Podczas treningu co stałą ilość kroków uczących zapisywałem wagi trenowanej sieci neuronowej. Wagi oraz model są wczytywane do testowania, a następnie zliczane są pojazdy które zakończyły symulację z dodatnią bądź ujemną nagrodą w przeciągu 100000 kroków. Poniższe wykresy przedstawiają zmiany wyników testów wszystkich trenowanych sieci. Spośród wszystkich zapisanych modeli wybrałem 3 modele do dalszej analizy: bezpieczny z najmniejszą ilością zniszczonych pojazdów, niebezpieczny z najmniejszą proporcją pojazdów osiągających cel do pojazdów zniszczonych oraz szybki z największą ilością pojazdów które osiągnęły cel. Następne wykresy przedstawiają otrzymaną nagrodę przez 3 wybrane modele na tle wszystkich trenowanych modeli w tym scenariuszu.

8.1 Pierwszy scenariusz

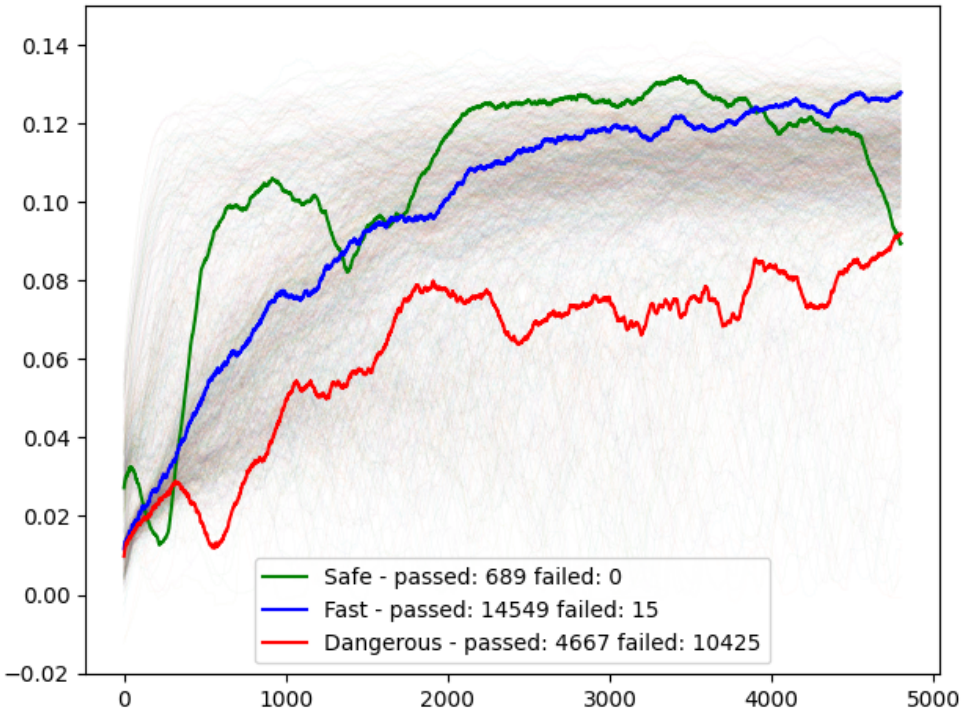

Rysunek 5: Wyniki testu w pierwszym środowisku.

Agent type	living penalty	depth	width	eps end	eps decay	batch size
danger	1.0	10	25	0.1	10000	128
fast	0.01	5	200	0.01	10000	32
safe	0.25	5	25	0.01	1000	32

8.2 Drugi scenariusz

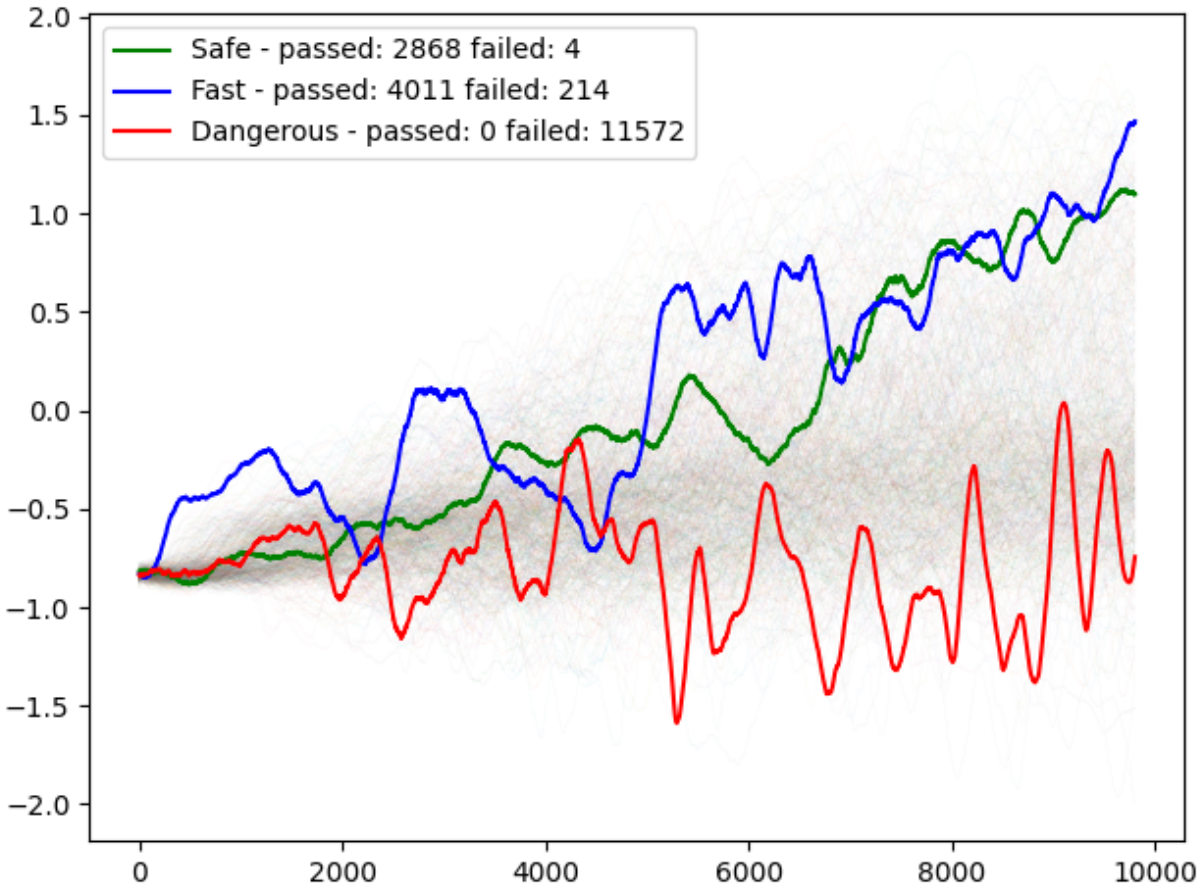

Rysunek 6: Wyniki testu w drugim środowisku.

Agent type	depth	width	eps end	memory size	target update	batch size	living penalty
danger	10	100	0.01	5000	500	128	0
fast	10	200	0.1	100000	1000	256	0.1
safe	20	200	0.1	100000	5000	128	0.05

8.3 Trzeci scenariusz

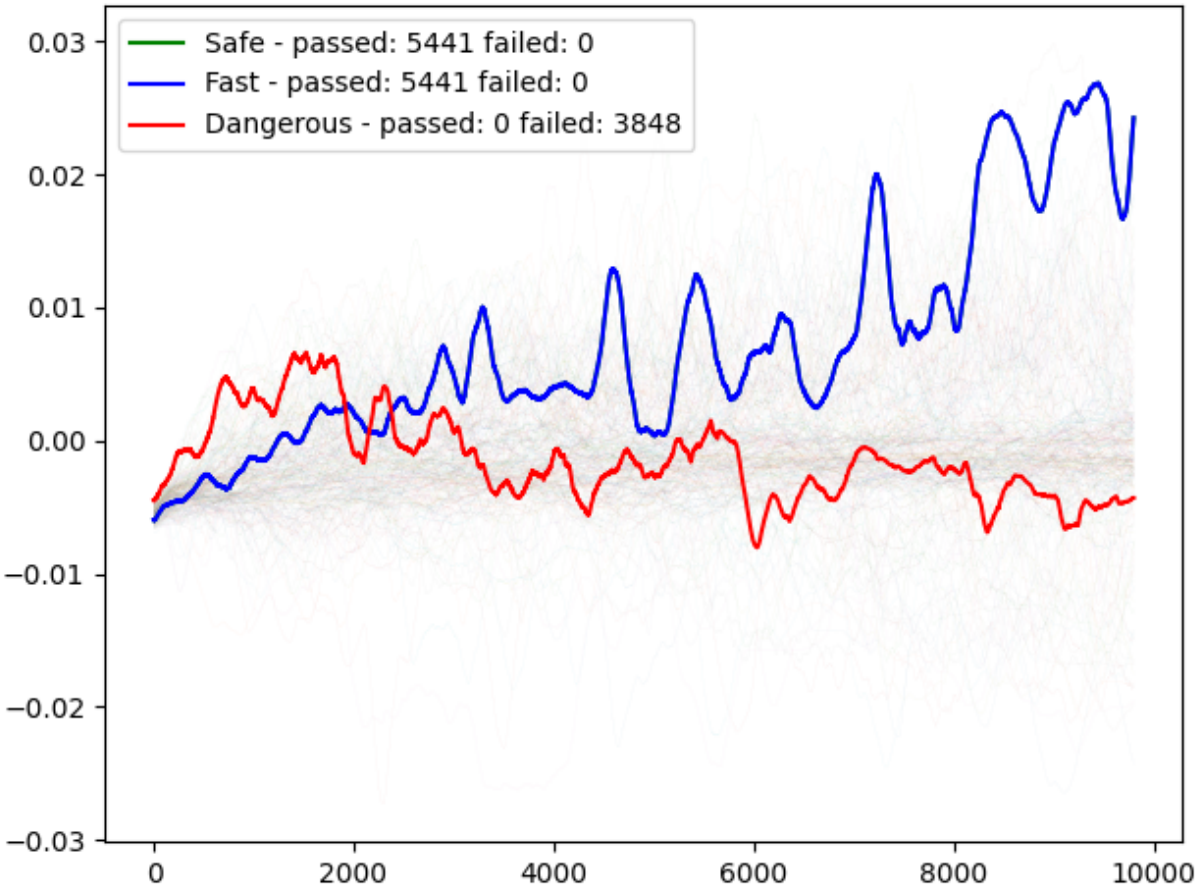

Rysunek 7: Wyniki testu w trzecim środowisku.

Agent type	eps end	eps decay	memory size	lr
danger	0.1	100000	10000	0.001
fast	0.01	1000000	100000	0.0001
safe	0.01	1000000	100000	0.0001

9 Analiza trzech agentów z pierwszego środowiska

Rysunek 8: Akcje wybrane podczas testów.

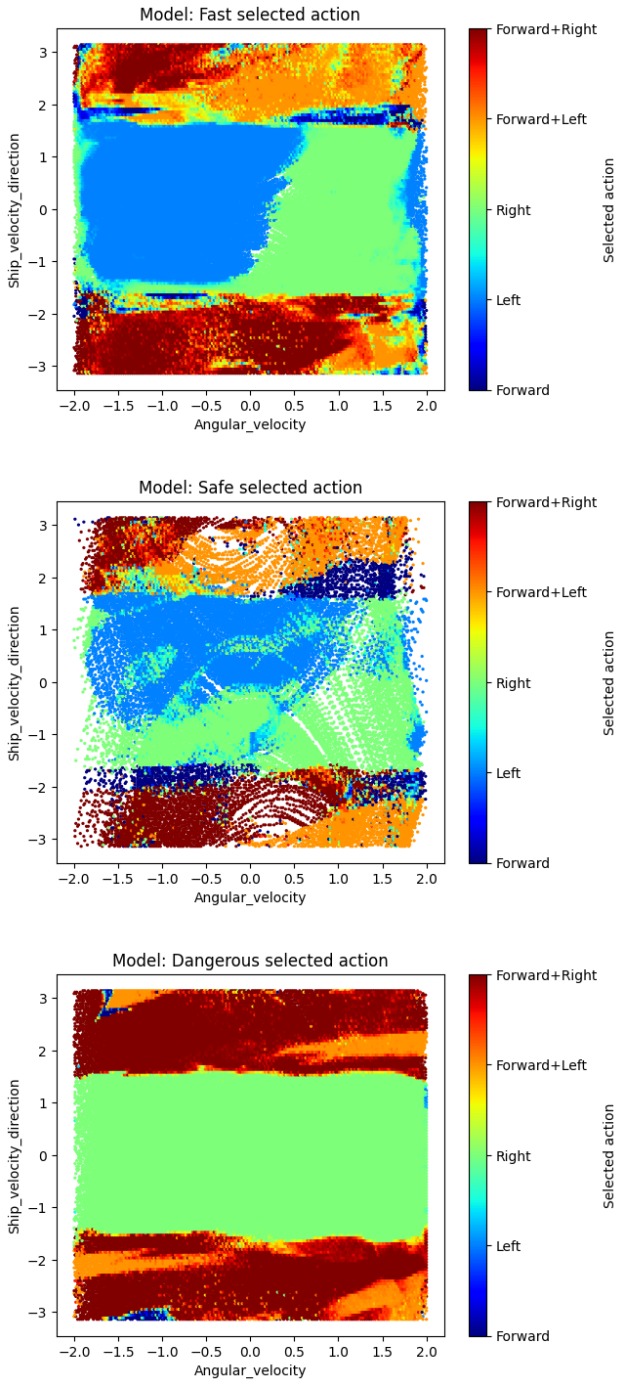

Na rysunku 8 znajdują się trzy wykresy przedstawiające wybrane przez trzech różnych agentów akcje podczas testowania. Stan przedstawiony jest na osiach. Oś X odpowiada prędkości obrotowej a oś Y kątowi pomiędzy kierunkiem statku a wektorem prędkości oraz prędkości kątowej. Statek zwalnia najefektywniej w momencie kiedy pojazd zwrócony jest w przeciwną stronę co prędkość, czyli wartość na osi Y jest bliska π *rad* bądź $-\pi$ *rad*. Dobrą akcją jest również uruchomienie głównego silnika kiedy kąt wynosi ponad $\pi/2$ *rad* bądź $-\pi/2$ *rad*.

Agent bezpieczny ma na wykresie dużo białych plam odpowiadających braku obserwacji tego stanu. Wynika to z tego, że pomimo takiej samej ilości kroków uczących i obserwacji statek wykonywał sukcesywnie negującą się akcję uruchamiając prawy i lewy silnik utrzymując stałą prędkość i rotację pojazdu jak widać na załączonym poniżej rysunku 9. Agent jest najbezpieczniejszy bo wszystkie pojazdy odlatują w nieskończoną przestrzeń.

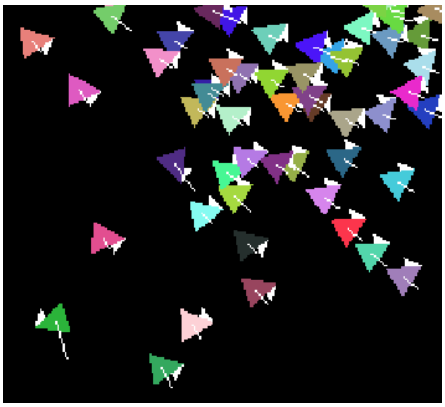

Rysunek 9: Cała populacja statków zablokowana przez strategię bezpiecznego agenta

Największą różnicę widać w środkowej części wykresów gdzie agent zwrócony jest przodem do kierunku lotu, to jest nie może jeszcze hamować. Agent niebezpieczny w ogóle nie korzysta z akcji skręcania w lewo. Wszystkie pojazdy przez większość stanów skręcają w prawo, co powoduje znaczącą zmianę dystrybucji obserwowanych stanów co wpływa na dalszą naukę agenta.

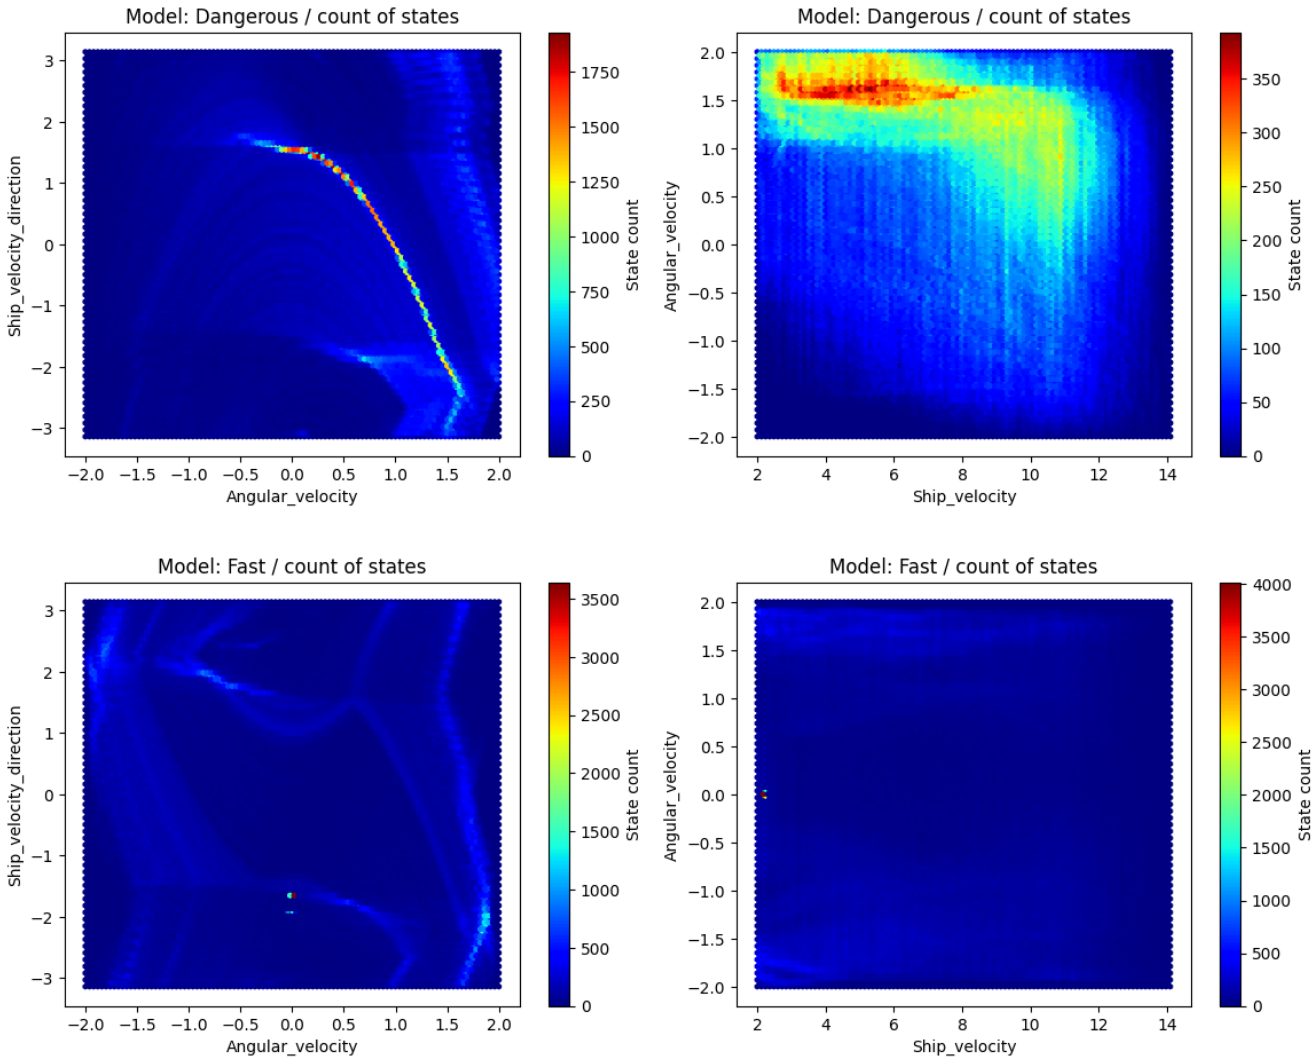

Rysunek 10: różnica w dystrybucji stanów obserwowanych podczas testów przez agenta niebezpiecznego i szybkiego. Chcę sprawdzić czym jest ten zielono czerwony punkt w dolnej części lewego dolnego wykresu

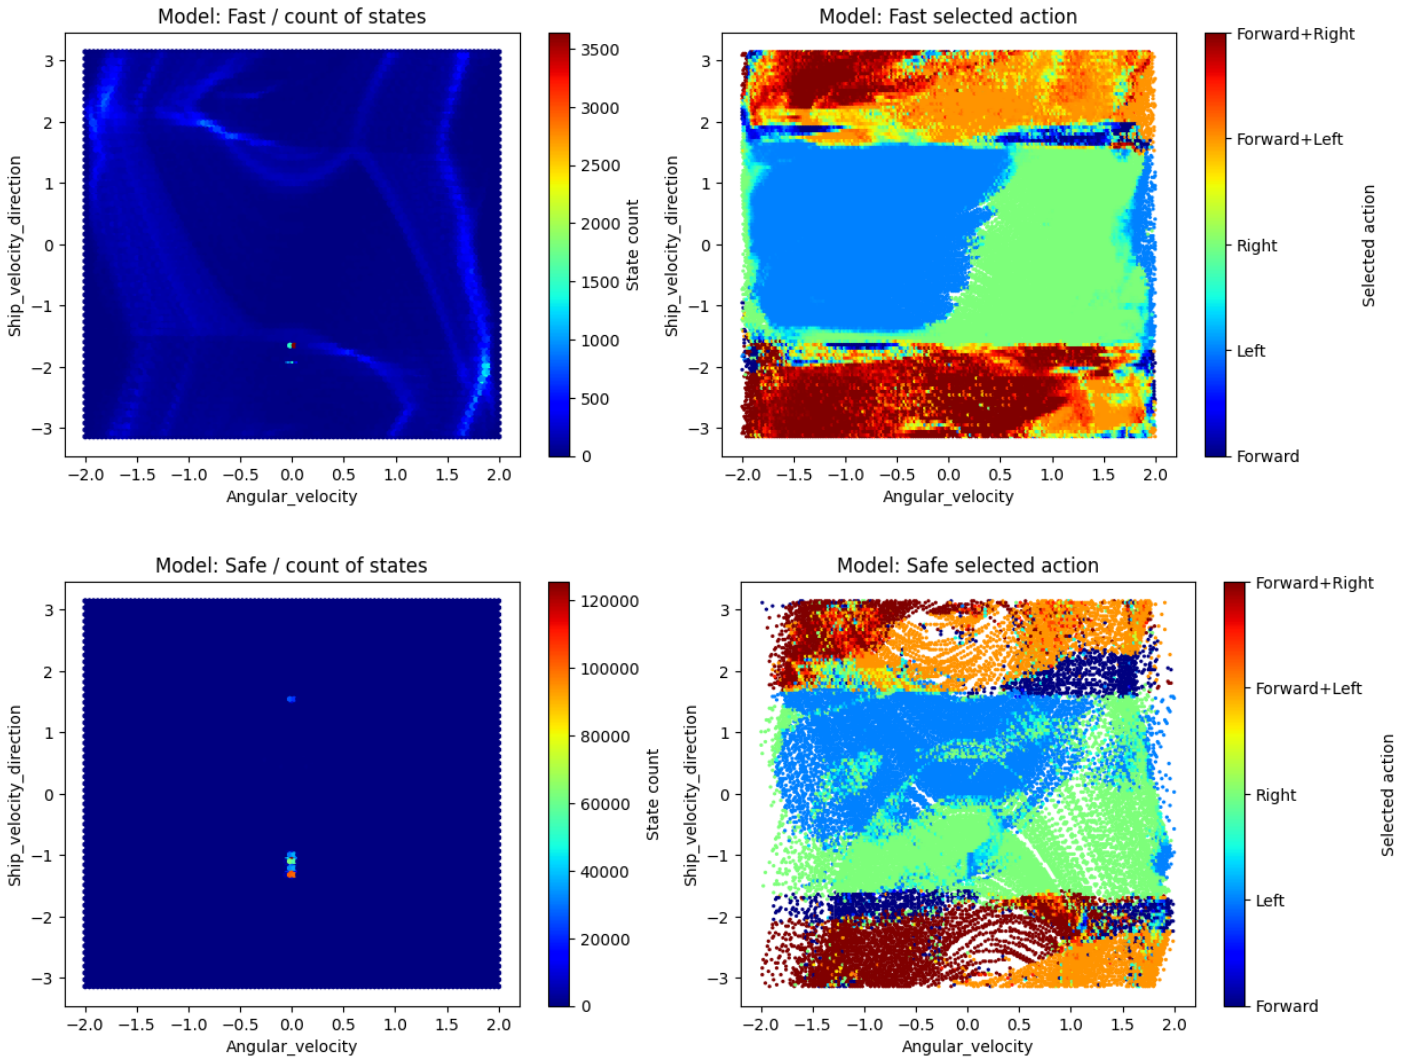

Rysunek 11: W podobnych miejscach jest czerwona plamka powodująca zapętlenie pojazdu w nieskończonym cyklu prawo/lewo. Chciałbym czerwonym markerem zaznaczyć dokładne miejsca w strategiach które powodują takie zachowanie

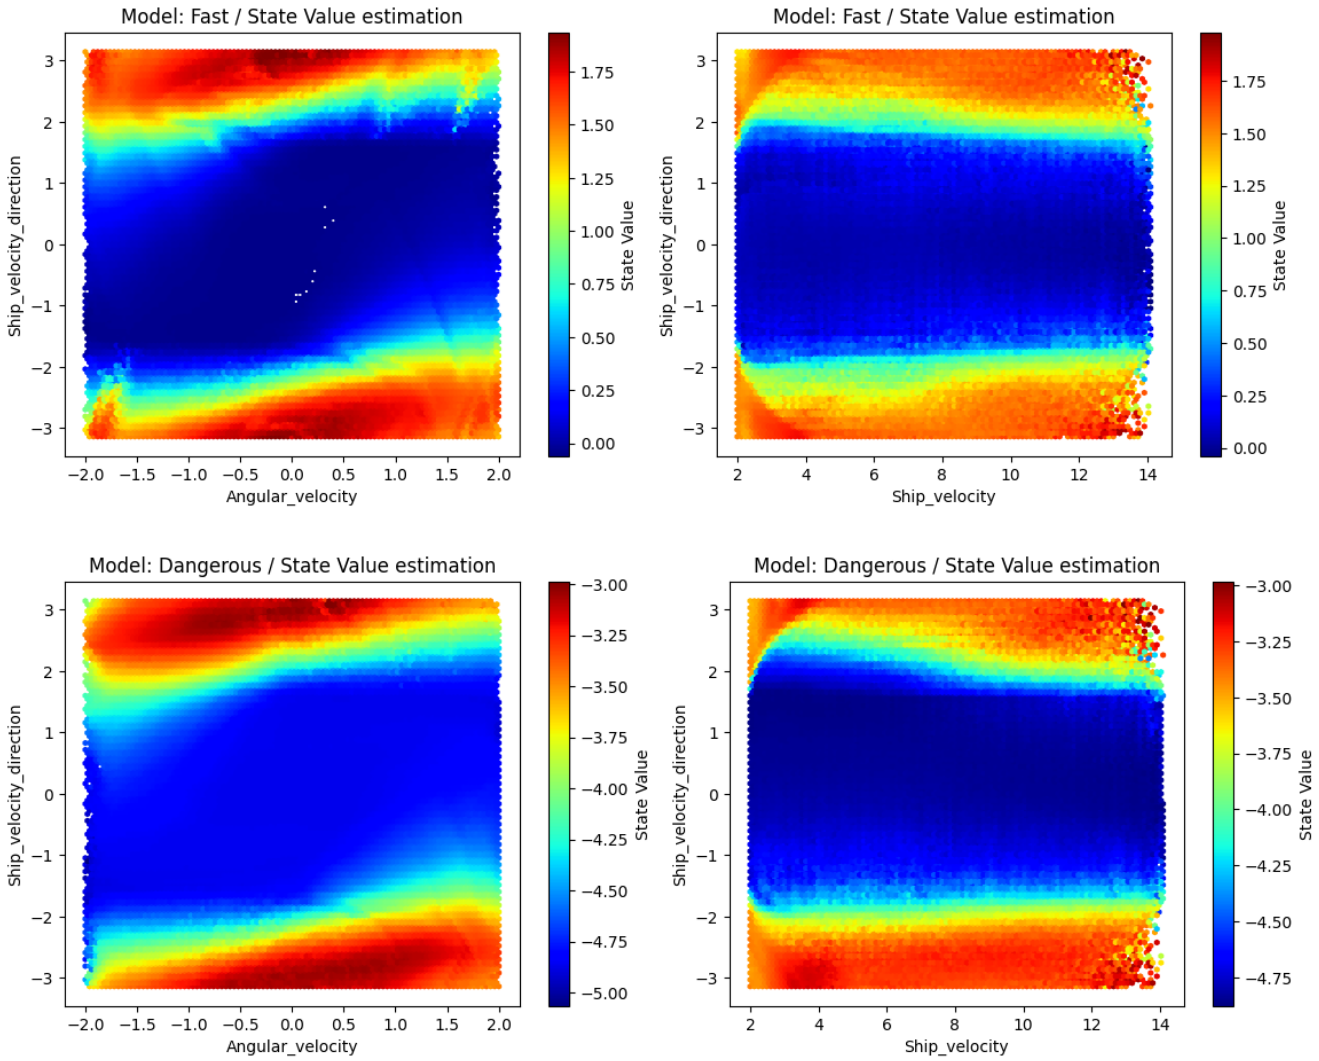

Rysunek 12: Wartości stanów wg szybkiego i niebezpiecznego są kształtem do siebie podobne, chociaż agent niebezpieczny przez living penalty przewiduje najlepszą oczekiwaną nagrodę -3

Literatura

[1] boost c++ libraries.

[2] Abien Fred Agarap. Deep learning using rectified linear units (relu). *CoRR*, abs/1803.08375, 2018.

[3] Ross B. Girshick. Fast R-CNN. *CoRR*, abs/1504.08083, 2015.

[4] Laurent Gomila. Simple and fast multimedia library sfml.

[5] Alex Graves. Generating sequences with recurrent neural networks. *CoRR*, abs/1308.0850, 2013.

[6] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Alex Graves, Ioannis Antonoglou, Daan Wierstra, and Martin Riedmiller. Playing atari with deep reinforcement learning, 2013.

[7] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d Alche-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 8024–8035. Curran Associates, Inc., 2019.

[8] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. A Bradford Book, Cambridge, MA, USA, 2018.

[9] Geoffrey Hinton with Nitish Srivastava Kevin Swersky. Neural networks for machine learning.

Spis rysunków

Spis tablic